

ProcessMind AI

Анализ и автоматизация бизнес-процессов: от PDF или схемы — к обоснованным рекомендациям и модельной оценке TO-BE

Финальный проект курса LLM Engineering

Все данные в проекте синтетические (демо-процессы, база знаний, Golden Dataset). Показатели «после автоматизации» — модельная оценка, а не прогноз.

Проблема

У аналитика есть регламент (PDF) или схема (картинка). Нужно понять, что в процессе стоит автоматизировать.

- вручную выписать операции, участников, длительности
- посчитать время и долю ручной работы
- найти подходящие способы автоматизации
- прикинуть эффект — чаще всего «на глаз»

Чем это плохо

- долго и не повторяется от аналитика к аналитику
- рекомендации без источников и условий применимости
- цифры эффекта ничем не подкреплены
- LLM «из коробки» легко выдумывает недостающие данные

Решение

Документ превращается в проверяемую структуру, а каждый шаг анализа опирается на данные, а не на догадки.



Не выдумывает

Нет участника или длительности — значение остаётся пустым и помечается.

LLM предлагает, код проверяет

ID операций, ссылки на паттерны и количественные утверждения проверяются программно.

Человек подтверждает

Workflow встаёт на паузу; допущения об эффекте задаёт пользователь.

Демо 1: извлечение процесса из PDF

- PDF → PyMuPDF → LLM (Structured Outputs) → ProcessSpec
- 8 операций; у части нет участника или длительности — **пусто, а не выдумано**
- таблица редактируется, схема AS-IS обновляется
- подтверждение пользователя — до анализа

2 Операции: просмотр и корректировка

Распознано операций: 8

Название процесса

Согласование заявки на закупку оборудования

Цель процесса

Обеспечить своевременное согласование и оформление закупки оборудо

Участники: Инициатор, Менеджер по закупкам, Финансовый директор, Бухгалтер

Исправьте название, участника, длительность или тип выполнения. Пустая ячейка = значение не указано.

№	Операция	Участник	Длительность, мин	Тип выполнения	Следующие
1	Подача заявки на закупку оборудования	Инициатор	None	Не указано	2
2	Проверка комплектности заявки	Менеджер по закупкам	30	Ручная	3
3	Согласование бюджета закупки	Финансовый директор	120	Не указано	4
4	Выбор поставщика	Менеджер по закупкам	None	Ручная	5
5	Заключение договора с поставщиком	None	4320	Не указано	6
6	Оплата счёта	Бухгалтер	60	Автоматизированная	7
7	Приём поставленного оборудования	Инициатор	None	Не указано	8
8	Закрытие заявки	Менеджер по закупкам	5	Автоматизированная	—

Демо 2: анализ, пауза и TO-BE

- метрики AS-IS считает MCP-сервер
- паттерны из RAG, рекомендации со ссылками
- **пауза** (interrupt): пользователь выбирает рекомендации и задаёт длительность после автоматизации
- сравнение AS-IS / TO-BE — «модельная оценка», отчёт в Markdown

Все показатели «после автоматизации» — модельная оценка на основе заданных предположений (длительностей операций после автоматизации и числа запусков процесса), а не измерение и не прогноз.

2 Сравнение AS-IS и TO-BE			
Показатель	AS-IS	TO-BE (модельная оценка)	Изменение
Общее время процесса (один экземпляр) Суммы неполные: у части операций длительность не указана	4535 мин (≈ 3,1 дн)	4510 мин (≈ 3,1 дн)	−25 мин (−0,55%)
Ручных операций Тип выполнения не указан у 4 операций — они не считаются ручными	2	1	−1
Доля ручных операций Если все операции с неуказанным типом ручные: 75% → 62%	25%	12%	−12 п.п.
Условная месячная трудоёмкость Число запусков процесса в месяц не задано	не указано	не указано	—

Мультимодальность: схема-картинка → процесс


- PNG/JPG обрабатывает GPT-4o-mini Vision (тот же SDK и схема ответа)
- Без Vision пользователь со схемой вместо регламента остался бы без анализа
- Дальше путь тот же: подтверждение → анализ → TO-BE

Честно: результат вероятностный. На демо-схеме связи прочитаны как ветвление, тип одной операции менялся от запуска к запуску. Приложение предупреждает и оставляет проверку пользователю.



Архитектура

Streamlit (4 страницы) → **parsing** (PyMuPDF · LLM · Vision) → подтверждённый ProcessSpec → **LangGraph**:



LangGraph и human-in-the-loop

- **Условные переходы:** `invalid`, `failed`, `no_recommendations`, `no_selection` ведут сразу в отчёт — это штатные исходы, а не исключения
- **Пауза:** `interrupt()` + `MemorySaver`; возобновление через `Command(resume=...)`
- **Цикл:** некорректное решение пользователя → повторный `interrupt` с текстом ошибки
- **Один граф, а не агенты:** задача линейная, поведение предсказуемо

«LLM предлагает, код проверяет»

- факты об операции подставляет код
- отброс: несуществующие операции, паттерны вне найденных, уже автоматизированные операции
- отброс количественных утверждений об эффекте
- длительность после автоматизации — допущение пользователя

RAG: база знаний паттернов

- 14 синтетических паттернов автоматизации (Markdown)
- chunking по смысловым разделам: проблема, условия, подход, эффект, ограничения
- text-embedding-3-small + ChromaDB (cosine), Top-3
- поиск по смыслу, не по ключевым словам
- reranker не используется

Метрика (23 positive)	Значение
Retrieval Hit@3	19/23 (83%)
Recall@3, среднее	0.826
Hit по пулу workflow	87%
Задержка поиска, среднее	0.28 с

Промахи: GD-002, GD-003, GD-015, GD-018.

MCP-сервер и Skill

MCP-сервер (свой, отдельный процесс, stdio)

- `validate_process` — проверка структуры и логики
- `calculate_process_metrics` — время, доля ручных, известное и неизвестное
- `simulate_automation` — ТО-БЕ по допущениям пользователя

Расчёты — обычный Python, без LLM и без «типового процента сокращения».

Skill process-analysis

- `SKILL.md`: описание, триггеры, методика
- правила выявления ручных операций и выбора паттернов
- требования к обоснованию, запрет выдумывать факты
- тот же файл — системный промпт LLM-узла; читается с диска при каждом запуске, sha256 — в отчёте

Оценки и A/B: LLM без RAG (A) и с RAG (B)

Метрика (30 примеров)	A: без RAG	B: с RAG
Recommendation F1, macro (по смыслу)	0.696	0.725
Отрицательные: корректно нет рекомендаций (n=4)	4/4	1/4
Рекомендации со ссылкой на паттерн	0%	100%
Разобраны условия применимости	0%	100%
Токены prompt, среднее	6334	8341
Латентность сквозная, среднее	5.14 с	8.11 с

Вывод: RAG не дал устойчивого прироста точности (+0.029 сейчас, −0.014 в другом прогоне — шум), но дал прослеживаемость. Выбран ради объяснимости рекомендаций, цена — токены и задержка.

Golden Dataset: 30 примеров (23 positive, 4 negative, 3 ambiguous). Один запуск на конфигурацию, выборка малая, датасет синтетический — оценки вероятно оптимистичны.

Модель, гиперпараметры и ограничения

Параметр	Значение и основание
LLM	gpt-4o-mini: Structured Outputs + Vision, ≈ \$0.0016 за анализ; другие модели не сравнивались
temperature	0.0 — эксперимент (6 примеров × 2 × 3 seed): 0.7 не дал прироста F1 (в другом прогоне был; шум)
top_p	1.0 — не варьировался
max_tokens	4096 — максимум наблюдаемого ответа 809

Что не сделано / не подтверждено

- LangSmith: трейс анализа проверен через API (37 runs); веб-дашборд визуально не проверялся
- Vision: связи и типы операций нестабильны
- нет fallback-модели и кэша ответов
- состояние паузы — в памяти процесса
- данных об обратной связи реальных пользователей в проекте нет

Выводы и что дальше

Что получилось

- сквозной продукт: документ → процесс → рекомендации → TO-BE → отчёт
- надёжность — за счёт архитектуры: строгие схемы, проверка кодом, расчёты в MCP, человек в цикле
- честная оценка, включая неудобный результат про RAG
- 415 автоматических тестов проходят

Дальше

- реальные (обезличенные) процессы и обратная связь
- сравнение моделей, fallback и кэш
- персистентное состояние графа
- точное чтение связей на схемах
- настроенный дашборд LangSmith с оценками качества