

# ProcessMind AI

Анализ и автоматизация бизнес-процессов: от PDF или схемы — к обоснованным рекомендациям и модельной оценке TO-BE

Финальный проект курса LLM Engineering

Все данные в проекте синтетические (демо-процессы, база знаний, Golden Dataset). Показатели «после автоматизации» — модельная оценка, а не прогноз.

# Проблема

У аналитика есть регламент (PDF) или схема (картинка). Нужно понять, что в процессе стоит автоматизировать.

- вручную выписать операции, участников, длительности
- посчитать время и долю ручной работы
- найти подходящие способы автоматизации
- прикинуть эффект — чаще всего «на глаз»

## Чем это плохо

- долго и не повторяется от аналитика к аналитику
- рекомендации без источников и условий применимости
- цифры эффекта ничем не подкреплены
- LLM «из коробки» легко выдумывает недостающие данные

# Решение

Документ превращается в проверяемую структуру, а каждый шаг анализа опирается на данные, а не на догадки.



## Не выдумывает

Нет участника или длительности — значение остаётся пустым и помечается.

## LLM предлагает, код проверяет

ID операций, ссылки на паттерны и количественные утверждения проверяются программно.

## Человек подтверждает

Workflow встаёт на паузу; допущения об эффекте задаёт пользователь.

# Демо 1: извлечение процесса из PDF

- PDF → PyMuPDF → LLM (Structured Outputs) → ProcessSpec
- 8 операций; у части нет участника или длительности — **пусто, а не выдумано**
- таблица редактируется, схема AS-IS обновляется
- подтверждение пользователя — до анализа

**2** Операции: просмотр и корректировка

Распознано операций: 8

Название процесса

Согласование заявки на закупку оборудования

Цель процесса

Обеспечить своевременное согласование и оформление закупки оборудо

Участники: Инициатор, Менеджер по закупкам, Финансовый директор, Бухгалтер

Исправьте название, участника, длительность или тип выполнения. Пустая ячейка = значение не указано.

| № | Операция                              | Участник             | Длительность, мин | Тип выполнения     | Следующие |
|---|---------------------------------------|----------------------|-------------------|--------------------|-----------|
| 1 | Подача заявки на закупку оборудования | Инициатор            | None              | Не указано         | 2         |
| 2 | Проверка комплектности заявки         | Менеджер по закупкам | 30                | Ручная             | 3         |
| 3 | Согласование бюджета закупки          | Финансовый директор  | 120               | Не указано         | 4         |
| 4 | Выбор поставщика                      | Менеджер по закупкам | None              | Ручная             | 5         |
| 5 | Заключение договора с поставщиком     | None                 | 4320              | Не указано         | 6         |
| 6 | Оплата счёта                          | Бухгалтер            | 60                | Автоматизированная | 7         |
| 7 | Приём поставленного оборудования      | Инициатор            | None              | Не указано         | 8         |
| 8 | Заккрытие заявки                      | Менеджер по закупкам | 5                 | Автоматизированная | —         |

# Демо 2: анализ, пауза и TO-BE

- метрики AS-IS считает MCP-сервер
- паттерны из RAG, рекомендации со ссылками
- **пауза** (interrupt): пользователь выбирает рекомендации и задаёт длительность после автоматизации
- сравнение AS-IS / TO-BE — «модельная оценка», отчёт в Markdown

Все показатели «после автоматизации» — модельная оценка на основе заданных предположений (длительностей операций после автоматизации и числа запусков процесса), а не измерение и не прогноз.

| 2 Сравнение AS-IS и TO-BE                                                                                        |                     |                          |                  |
|------------------------------------------------------------------------------------------------------------------|---------------------|--------------------------|------------------|
| Показатель                                                                                                       | AS-IS               | TO-BE (модельная оценка) | Изменение        |
| Общее время процесса (один экземпляр)<br><small>Суммы неполные: у части операций длительность не указана</small> | 4535 мин (≈ 3,1 дн) | 4510 мин (≈ 3,1 дн)      | −25 мин (−0,55%) |
| Ручных операций<br><small>Тип выполнения не указан у 4 операций — они не считаются ручными</small>               | 2                   | 1                        | −1               |
| Доля ручных операций<br><small>Если все операции с неуказанным типом ручные: 75% → 62%</small>                   | 25%                 | 12%                      | −12 п.п.         |
| Условная месячная трудоёмкость<br><small>Число запусков процесса в месяц не задано</small>                       | не указано          | не указано               | —                |

# Мультимодальность: схема-картинка → процесс


- PNG/JPG обрабатывает GPT-4o-mini Vision (тот же SDK и схема ответа)
- Без Vision пользователь со схемой вместо регламента остался бы без анализа
- Дальше путь тот же: подтверждение → анализ → TO-BE

**Честно:** результат вероятностный. На демо-схеме связи прочитаны как ветвление, тип одной операции менялся от запуска к запуску. Приложение предупреждает и оставляет проверку пользователю.



# Архитектура

Streamlit (4 страницы) → **parsing** (PyMuPDF · LLM · Vision) → подтверждённый ProcessSpec → **LangGraph**:



# LangGraph и human-in-the-loop

- **Условные переходы:** `invalid`, `failed`, `no_recommendations`, `no_selection` ведут сразу в отчёт — это штатные исходы, а не исключения
- **Пауза:** `interrupt()` + `MemorySaver`; возобновление через `Command(resume=...)`
- **Цикл:** некорректное решение пользователя → повторный `interrupt` с текстом ошибки
- **Один граф, а не агенты:** задача линейная, поведение предсказуемо

## «LLM предлагает, код проверяет»

- факты об операции подставляет код
- отброс: несуществующие операции, паттерны вне найденных, уже автоматизированные операции
- отброс количественных утверждений об эффекте
- длительность после автоматизации — допущение пользователя

# RAG: база знаний паттернов

- 14 синтетических паттернов автоматизации (Markdown)
- chunking по смысловым разделам: проблема, условия, подход, эффект, ограничения
- text-embedding-3-small + ChromaDB (cosine), Top-3
- поиск по смыслу, не по ключевым словам
- reranker не используется

| Метрика (23 positive)    | Значение    |
|--------------------------|-------------|
| Retrieval Hit@3          | 19/23 (83%) |
| Recall@3, среднее        | 0.826       |
| Hit по пулу workflow     | 87%         |
| Задержка поиска, среднее | 0.28 с      |

Промахи: GD-002, GD-003, GD-015, GD-018.

# МСП-сервер и Skill

## МСП-сервер (свой, отдельный процесс, stdio)

- `validate_process` — проверка структуры и логики
- `calculate_process_metrics` — время, доля ручных, известное и неизвестное
- `simulate_automation` — ТО-ВЕ по допущениям пользователя

Расчёты — обычный Python, без LLM и без «типового процента сокращения».

## Skill process-analysis

- `SKILL.md`: описание, триггеры, методика
- правила выявления ручных операций и выбора паттернов
- требования к обоснованию, запрет выдумывать факты
- тот же файл — системный промпт LLM-узла; читается с диска при каждом запуске, sha256 — в отчёте

# Оценки и А/В: LLM без RAG (А) и с RAG (В)

| Метрика (30 примеров)                           | А: без RAG | В: с RAG |
|-------------------------------------------------|------------|----------|
| Recommendation F1, macro (по смыслу)            | 0.725      | 0.710    |
| Отрицательные: корректно нет рекомендаций (n=4) | 3/4        | 1/4      |
| Рекомендации со ссылкой на паттерн              | 0%         | 100%     |
| Разобраны условия применимости                  | 0%         | 100%     |
| Токены prompt, среднее                          | 6334       | 8341     |
| Латентность сквозная, среднее                   | 4.24 с     | 7.18 с   |

**Вывод:** RAG не улучшил точность (−0.014 — в пределах шума), но дал прослеживаемость. Выбран ради объяснимости рекомендаций, цена — токены и задержка.

Golden Dataset: 30 примеров (23 positive, 4 negative, 3 ambiguous). Один запуск на конфигурацию, выборка малая, датасет синтетический — оценки вероятно оптимистичны.

# Модель, гиперпараметры и ограничения

| Параметр    | Значение и основание                                                                          |
|-------------|-----------------------------------------------------------------------------------------------|
| LLM         | gpt-4o-mini: Structured Outputs + Vision, ≈ \$0.0016 за анализ; другие модели не сравнивались |
| temperature | 0.0 — эксперимент (6 примеров × 2 × 3 seed) и правило, заданное заранее                       |
| top_p       | 1.0 — не варьировался                                                                         |
| max_tokens  | 4096 — максимум наблюдаемого ответа<br>881                                                    |

## Что не сделано / не подтверждено

- LangSmith: трейс проверен через API (37 runs), трейсы оценок не отправлялись
- Vision: связи и типы операций нестабильны
- нет fallback-модели и кэша ответов
- состояние паузы — в памяти процесса
- данных об обратной связи реальных пользователей в проекте нет

# Выводы и что дальше

## Что получилось

- сквозной продукт: документ → процесс → рекомендации → TO-BE → отчёт
- надёжность — за счёт архитектуры: строгие схемы, проверка кодом, расчёты в MCP, человек в цикле
- честная оценка, включая неудобный результат про RAG
- 415 автоматических тестов проходят

## Дальше

- реальные (обезличенные) процессы и обратная связь
- сравнение моделей, fallback и кэш
- персистентное состояние графа
- точное чтение связей на схемах
- трейсы 30 оценочных прогонов в LangSmith